

# Epilepsi Nöbetlerinin Tespiti için Bayesçi Değişim Noktası Modeli A Bayesian Change Point Model for Epileptic Seizure Detection

Çağatay Yıldız, Haluk O. Bingöl  
Bilgisayar Mühendisliği Bölümü  
Boğaziçi Üniversitesi  
İstanbul, Türkiye  
{cagatay.yildiz1, bingol}@boun.edu.tr

Gülçin İrim-Çelik, Berrin Aktekin, Canan Aykut-Bingöl  
Nöroloji Anabilim Dalı  
Yeditepe Üniversitesi  
İstanbul, Türkiye  
{girim, berrin.aktekin, caykutbingol}@yeditepe.edu.tr

**Özetçe** —Epilepsi, beyindeki sinirsel aktivitenin olağan dışılaşmasından kaynaklanan ve nöbetlere sebep olan bir hastalıktır. Epilepsi cerrahisinde, nöbet esnasında aktif olan beyin bölgesinin tespiti büyük öneme sahiptir. Bunu yapmanın yollarından biri, hastalardan elektroensefalografi (EEG) verileri toplanması ve nöbetlerin gerçekleştiği zaman dilimlerinde aktif olan bölgelerin belirlenmesidir. Biz bu çalışmada, bu zaman dilimlerini saptayan bir Bayesçi değişim noktası modeli sunuyoruz. Geliştirdiğimiz yöntemi, epilepsi hastalarından toplanan ve hastaların EEG ve elektrokardiyografi (EKG) kayıtlarını içeren 48 farklı veri kümesine uyguladık. Bütün örneklerde nöbetin gerçekleştiği aralığın başarıyla tespit edildiğini gözlemledik.

**Anahtar Kelimeler**—Epilepsi, Bayesçi Değişim Noktası Modeli

**Abstract**—Epilepsy is a chronic neurological disorder in which the normal pattern of neuronal activity in the brain becomes disturbed. Identification of the brain region that is abnormally active during an epileptic seizure is vital for epilepsy surgery. One way of achieving so is to collect electroencephalography (EEG) signals from epileptic people and then to identify the active region as a seizure occurs. In this work, we present a Bayesian change point model that detects when seizures occur. We applied our method to a data set that contains 48 EEG and electrocardiography (EKG) record pairs collected from epileptic people and observed that the model is able to detect all seizures.

**Keywords**—Epilepsy, Bayesian Change Point Model

## I. GİRİŞ

Epilepsi, en sık görülen nörolojik hastalıklar içinde üçüncü sırada yer almaktadır. Hastalık, beyinde yer alan sinir hücrelerinin geçici olarak aşırı boşalımı ya da aşırı senkronizasyonu sonucu ortaya çıkan ve epilepsi nöbetleri olarak adlandırılan tekrarlayıcı ataklarla tanımlanır. Epilepsi nöbetleri, beyinde ortaya çıktığı yere bağlı olarak istemsiz hareketler, farklı duygular, bilinç değişiklikleri gibi çok farklı değişikliklere sebep olabilir. Epilepsi hastalarının %70'inde nöbetler ilaçlar ile kontrol altına alınabildiği gibi nöbetlerin kaynaklandığı alan belirlenebilir ve bu alan hasarsız olarak çıkartılabilirse ameliyat

ile de kontrol altına alınması mümkündür.

Epilepsi cerrahisi öncesinde nöbetin kaynaklandığı alanı bulmak üzere nöbetler arası, özellikle de nöbet sırasında *elektroensefalografi* (EEG) ile elektriksel olarak aktif alan saptanmaya çalışılır. Hastalarda kafa derisi üzerinden kayıt toplanabileceği gibi kafaiçi elektrotlarla daha ayrıntılı incelemeler yapılması gerekebilmektedir. EEG ile beraber video kaydının alınmasının mümkün olduğu durumlarda nöbet sırasında görülen davranış değişiklikleri de incelenerek nöbetin kaynaklandığı alan anlaşılmasına çalışılır. Aynı zamanda, hastanın birden fazla nöbetinin kaydedilmesi, nöbet kaynağının daha iyi belirlenmesine katkıda bulunmaktadır. Sonuç olarak, EEG kayıtları görsel olarak nörolog tarafından değerlendirilirken, lateralizasyon ve lokalizasyon için EEG sinyallerinin işlenerek daha fazla bilgi sağlanması epilepsi cerrahisi başarısını artırabilecektir.

Epilepsi nöbetleri sırasında sinir hücrelerinin aktiviteğinde ani değişiklikler meydana geldiğinden, hastadan toplanan EEG sinyallerindeki salınımların nöbet esnasında olduğundan bekleriz. Bayesçi değişim noktası modellerinin zaman serilerindeki bu gibi ani değişikliklerin tespitinde başarılı olduğu daha önceki çalışmalarda gösterilmiştir [1], [2]. Biz bu çalışmada, epilepsi hastalarından toplanan ve nörologlar tarafından nöbet başlangıç ve bitiş anları işaretlenen EEG sinyallerinde, Bayesçi değişim noktası modelinin nöbetin gerçekleştiği zaman dilimini bulup bulamayacağını test ettik.

Makalenin geri kalanı şu şekilde düzenlenmiştir: Bir sonraki bölüm, epilepsi nöbetlerinin EEG kayıtları yardımıyla algoritmik olarak tespiti üzerine daha önceki çalışmaları özetlemektedir. Bölüm III'te, değişim noktası modelinin detaylarını sunuyoruz. Ham EEG kayıtlarından modele girdi oluşturma yöntemimiz Bölüm IV'te anlatılmaktadır. Bölüm V, deney ortamımızı ve sonuçları ele alırken son bölümde vargıları ve ileri çalışmaları anlatıyoruz.

## II. İLGİLİ ÇALIŞMALAR

Epilepsi nöbetlerinin tespiti konusundaki çalışmaları kabaca iki kategoriye ayırabiliriz: klasik sinyal işleme ve yapay öğrenmeye dayanan yöntemler. İlk kategorinin iyi bilinen örneklerinden birinde Khan ve Gotman dalgacık (*wavelet*) tabanlı bir yöntemle farklı frekans aralıklarının nöbetin belirlenmesine olan etkisini incelemişlerdir [3]. Adeli ve diğerleri, üç farklı EEG veri kaynağını (sağlıklı insanlar, epilepsi hastalarının nöbet esnasındaki ve normal anlarındaki kayıtları) analiz eden bir dalgacık-kaos yöntemi sunmuşlardır [4]. Radhakrishnan ve Gangadhar'ın çalışmasında, nöbetler esnasında yaklaşık entropinin (*approximate entropy* - *ApEn*) düştüğü gösterilmiştir [5]. Diambra, Figueiredo ve Malta, *ApEn* yardımıyla değişik tipteki epilepsi nöbetlerini saptamayı başarmıştır [6].

Literatürde, EEG sinyallerinde bir ön işlemenin ardından yapay sinir ağları (*artificial neural networks* - *ANN*) yardımıyla nöbet tespitini gerçekleştiren birçok çalışma bulunmaktadır. Bunlardan birinde Srinivasan ve diğerleri, *ApEn*'i ANN ile birleştirerek %100'e kadar ulaşan başarımla oranına erişilebileceğini göstermiştir [7]. Guo ve diğerleri, çoklu dalgacık dönüşümü (*multiwavelet transform*) ve *ApEn*'i ANN ile birleştirmiştir [8]. İstatistiksel analize dayanan başka bir yöntemde Evrim ve diğerleri, paralel faktör analiziyle (*PARAFAC*) nöbetleri modellemeye çalışmışlardır [9]. Dhulekar ve diğerlerinin çalışmasında, EEG sinyallerinden oluşturulan çizgelerin zaman içinde değişimlerine bakılmıştır [10]. Alotaiby ve diğerlerinin yakın zamanlarda yazdığı makaleden bu konuyla ilgili daha fazla çalışmayı tanımak mümkündür [11].

## III. BAYESÇİ DEĞİŞİM NOKTASI MODELİ

Bayesçi değişim noktası modeli, hiyerarşik saklı Markov modellerinin örneklerinden biridir [12]. Modelde gözlemleri  $v$ , saklı değişkenleriyse  $s$  ve  $h$  ile gösteriyoruz (Grafik model Şekil 1'de verilmiştir). Bizim problemimizde gözlemler hastalardan toplanan verilerden çıkardığımız özniteliklere karşılık gelirken saklı değişkenlerimizden  $s$  hastanın nöbette olup olmadığını,  $h$  ise sinyalleri ürettiği kabul edilen parametreleri temsil etmektedir. Modelin nihai amacı, gözlemler verildiğinde, değişim noktası olasılığının sonsal dağılımını hesaplamaktır. Açıkçası, hesaplamaya çalıştığımız büyüklük aşağıda verilmiştir:

$$p(s|v) = \frac{p(v|s)p(s)}{p(v)} \propto \int p(v|h, s)p(h|s)p(s)dh \quad (1)$$

### A. Üreteç Model

Kimi özel durumlar dışında (1)'de verilen tümlevi hesaplamak mümkün değildir [12]. Bu özel durumlardan biri, değişimi temsil eden  $s_t$ 'nin bir ikili değişken olduğu ve  $s_t$ 'nin değerine bağlı olarak rejimin sıfırlandığı ya da değişmeden devam ettiği senaryodur. Literatürde *reset modelleri* [1] olarak da bilinen bu modelin üreteç modeli aşağıdaki gibidir:


$$h_0 \sim \Omega(h_0; w) \quad (2)$$

$$s_t \sim [s_t = 0]\pi + [s_t = 1](1 - \pi) \quad (3)$$

$$h_t|s_t, h_{t-1} \sim [s_t = 0]\delta(h_t - h_{t-1}) + [s_t = 1]\Omega(h_t; w) \quad (4)$$

$$v_t|h_t \sim \Theta(v_t; h_t) \quad (5)$$

Burada  $\delta$  Dirac delta fonksiyonuna,  $\Omega(h_t; w)$  sıfırlanma dağılımına ve  $\Theta(v_t; h_t)$  gözlem modeline karşılık gelmektedir.



Şekil 1: Bayesçi değişim noktası modelinin grafik modeli

Üreteç modelin iki parametresi  $\pi$  ve  $w$ , sırasıyla, değişim olasılığının ve sıfırlanma dağılımının önsel dağılım parametreleridir.

Model,  $t$  anındaki gözlem  $v_t$ 'nin, parametresi  $h_t$ 'yi bilmediğimiz  $\Theta(v_t; h_t)$  dağılımından örneklenen bir rasgele değişken olduğunu kabul etmektedir. Bayesçi yöntemlerin bir gereği olarak, çıkarım esnasında  $h_t$  değerlerini belirli bir değere sabitlemiyoruz. Bunun yerine,  $h_t$  üzerindeki belirsizliği bir olasılık dağılımıyla,  $p(h_t|s_t, h_{t-1})$ , modelliyoruz. Görüldüğü üzere  $h_t$ 'nin değeri modelin sıfırlanıp sıfırlanmamasına, yani  $s_t$ 'nin değerine bağlıdır. Model sıfırlandığında ( $s_t = 1$ )  $h_t$ 'nin geçmişle bağlantısı kesilmekte (*resetting*) ve  $h_t$  bir  $\Omega(h; w)$  dağılımından örneklenmekte;  $s_t = 0$  iken bu değer sabit kalmaktadır ( $h_t = h_{t-1}$ ). Epilepsi nöbetleri esnasında nöron aktiviterinde büyük farklılıklar meydana geleceğinden bu anlarda sıfırlanma olasılığının yüksek çıkmasını beklemekteyiz.

### B. Sonsal Dağılımın Hesaplanması

Herhangi bir  $t$  anı için değişim noktası tespiti problemi,  $s_t$ 'nin sonsal dağılımını hesaplamaya karşılık gelir. Gerçek zamanlı problemlerde bu büyüklük süzgeçleme dağılımı (*filtering distribution*)  $p(s_t|v_{1:t})$  iken çevrimdışı çalışmanın mümkün olduğu durumlarda sonsal dağılımı bütün gözlemlere dayanarak hesaplayabiliriz:  $p(s_t|v_{1:T})$  (yumuşatılmış dağılım, *smoothed distribution*). Bu dağılımları hesaplarken öncelikle Bayes kuralından faydalanırız:

$$p(s_t|v_{1:T}) = \frac{p(v_{1:T}, s_t)}{p(v_{1:T})} \propto p(v_{1:T}, s_t) \quad (6)$$

$p(v_{1:T}, s_t)$  dağılımını hesaplamak için bir dinamik programlama yöntemi olan İleri Yönlü-Geri Yönlü (*Forward-Backward*) algoritmayı (İGA) kullanabiliriz. Öncelikle süzgeçleme dağılımını hesaplamak için tanımlamamız gereken ileri yönlü mesajı ve özyineleme denklemini görelim:

$$\alpha(s_t, h_t) \equiv p(s_t, h_t, v_{1:t}) \quad (7)$$

$$= \sum_{s_{t-1}} \int_{h_{t-1}} p(s_{t-1}, s_t, h_{t-1}, h_t, v_{1:t}) \quad (8)$$

$$= \sum_{s_{t-1}} \int_{h_{t-1}} p(h_t|h_{t-1}, s_t)\alpha(s_{t-1}, h_{t-1})dh_{t-1} \times p(v_t|h_t) \times p(s_t) \quad (9)$$

Değişim noktası ihtimali, ileri yöndeki mesaj üzerinden tümlev olarak bulunabilir:

$$p(s_t|v_{1:t}) \propto p(s_t, v_{1:t}) = \int_{h_t} \alpha(s_t, h_t)dh_t \quad (10)$$

Yumuşatılmış dağılımı hesaplamak için, geri yöndeki mesajları ve özyineleme denklemini tanımlamamız gerekmektedir:

$$\beta(s_t, h_t) \equiv p(v_{t+1:T} | s_t, h_t) \quad (11)$$

$$= \sum_{s_{t+1}} \int_{h_{t+1}} p(s_{t+1}, h_{t+1}, v_{t+1:T} | s_t, h_t) \quad (12)$$

$$= \sum_{s_{t+1}} \int_{h_{t+1}} p(h_{t+1} | h_t, s_{t+1}) \beta(s_{t+1}, h_{t+1}) dh_{t+1} \times p(v_t | h_t) \times p(s_t) \quad (13)$$

Bütün gözlemlere dayalı değişim noktası, ileri ve geri yöndeki mesajların çarpımı üzerinden tümlev olarak hesaplanır:

$$p(s_t | v_{1:T}) \propto \int_{h_t} p(s_t, h_t, v_{1:T}) p(v_{t+1:T} | s_t, h_t) \quad (14)$$

$$= \int_{h_t} \alpha(s_t, h_t) \beta(s_t, h_t) dh_t \quad (15)$$

### C. Sıfırlanma ve Gözlem Modeli

İGA'daki hesaplamalar, sıfırlanma ve gözlem modellerinin çarpılmasını gerektirmektedir. Sıfırlanma dağılımı  $\Omega(h; w)$ 'nin, gözlem dağılımı  $\Theta(v; h)$ 'nin eşlenik dağılımı (*conjugate prior*) olduğu durumda bu çarpmanın sonucu kolaylıkla hesaplanabilir. Biz bu çalışmada sıfırlanma ve gözlem modeli olarak Gamma ve Poisson dağılımlarını ele aldık. Matematiksel olarak, gözlemlerimizin  $N$  boyutlu olduğu durumda kullandığımız sıfırlanma ve gözlem modelleri şöyledir:

$$\Omega(h; w) = \prod_{i=1}^N \mathcal{G}(h_i; a, b) \quad (16)$$

$$\Theta(v; h) = \prod_{i=1}^N \mathcal{P}(v_i; h_i) \quad (17)$$

Burada  $\mathcal{G}(\cdot; \cdot, \cdot)$  ve  $\mathcal{P}(\cdot; \cdot)$  sırasıyla Gamma ve Poisson dağılımını temsil eder. Sıfırlanma modeli Gamma dağılımlarının çarpımından meydana geldiği için  $w$ , bu dağılımın şekil ( $a$ ) ve ölçek ( $b$ ) parametrelerine karşılık gelmektedir.

### IV. VERİ KÜMEMİZİN NİTELİKLERİ

Veri kümemiz, epilepsi hastalarından toplanan EEG ve *elektrokardiografi* (EKG) kayıt çiftlerinden meydana gelmektedir. Her bir çift, 16-19 kanaldan toplanan EEG sinyallerini ve 2 EKG kanalını içermektedir. Bu kayıtlar, epilepsi cerrahisi düşüncesiyle kayıtları alınan ve cerrahi sonrasında nöbetleri kalmamış olan hastalardan derlenmiştir. Dolayısıyla bazı hastaların bir, bazılarının beşe kadar nöbet kayıtları vardır. Girdi olarak kayıtların tamamı yerine nörologun zamanını belirlediği nöbetin yaklaşık 30 dakika öncesi ve nöbetten sonraki 30 dakikalık kısımları kullandık.

Veri kümemizdeki  $i$ 'nci kaydı  $N_i \times T_i$  boyutlu  $\mathbf{X}_i$  matrisiyle göstermekteyiz,  $i \in \{1, \dots, 48\}$ . Burada  $N_i$  kanalları,  $T_i$  veri sayısını gösterir.  $\mathbf{X}_i$ 'nin ilk  $N_i - 2$  satırında EEG, son iki satırıysa EKG kayıtları yer alır. Kayıtların ortalama uzunluğunun bir saat civarında olduğunu ve  $F_i$  ile gösterdiğimiz örneklem frekansının 200 ya da 400 olduğunu dikkate aldığımızda,  $T_i$ 'nin  $N_i$ 'den çok büyük olduğunu söyleyebiliriz:  $T_i \gg N_i$ .

Epilepsi nöbetleri esnasında olağan sinirsel aktiviteden büyük sapmalar meydana geldiği için,  $\mathbf{X}_i$  üzerinde bir pencere kaydardığımızda, birbirini takip eden iki pencere arasındaki sapmanın nöbet esnasında çok yüksek olmasını bekleriz. Bu sebeple, Bayeşçi değişim noktası modelimize girdi türetmek için,  $\mathbf{X}_i$  üzerinde genişliği  $W_i$  olan pencereler kaydardık ve her ardışık pencere ikilisi arasındaki farkın mutlak değerinin gözlemler üzerinden toplamını kaydettik. En iyi  $W_i$  değeri, hastadan alınan kayıtlarla direkt alakalı olduğundan deneylerimizde  $k \in \{0.2, 0.5, 1, 2, 4, 10\}$  saniye genişliğinde pencereleri değerlendirdik ( $W_i = kF_i$ ). Sonuç olarak *pencereler arası fark matrisi* (PAFM) adını verdiğimiz,  $N_i \times D_i$  boyutlu matrisler elde ettik ( $D_i = \frac{T_i}{kF_i} - 1$ ).

Verinin toplandığı kanallardaki sinyallerin ortalama büyüklükleri, kanaldan kanala ciddi farklılıklar arz edebilir. Ortalama büyüklüğü daha fazla olan sinyallerin değişim noktası kararına etkisi fazla olduğundan deneyleri *satırları düzelenmiş* (*normalized*) *pencereler arası fark matrislerinin* (SD-PAFM) üzerinde gerçekleştirdik. İlaveyen, EEG ve EKG kayıtlarının kendi başlarına nöbet tespitinde başarılı olup olmayacaklarını görmek adına SD-PAFM'nin ilk  $N_i - 2$  ve son iki satırını değişim noktası modelimize ayrı girdiler olarak verdik (SD-PAFM-EEG ve SD-PAFM-EKG).

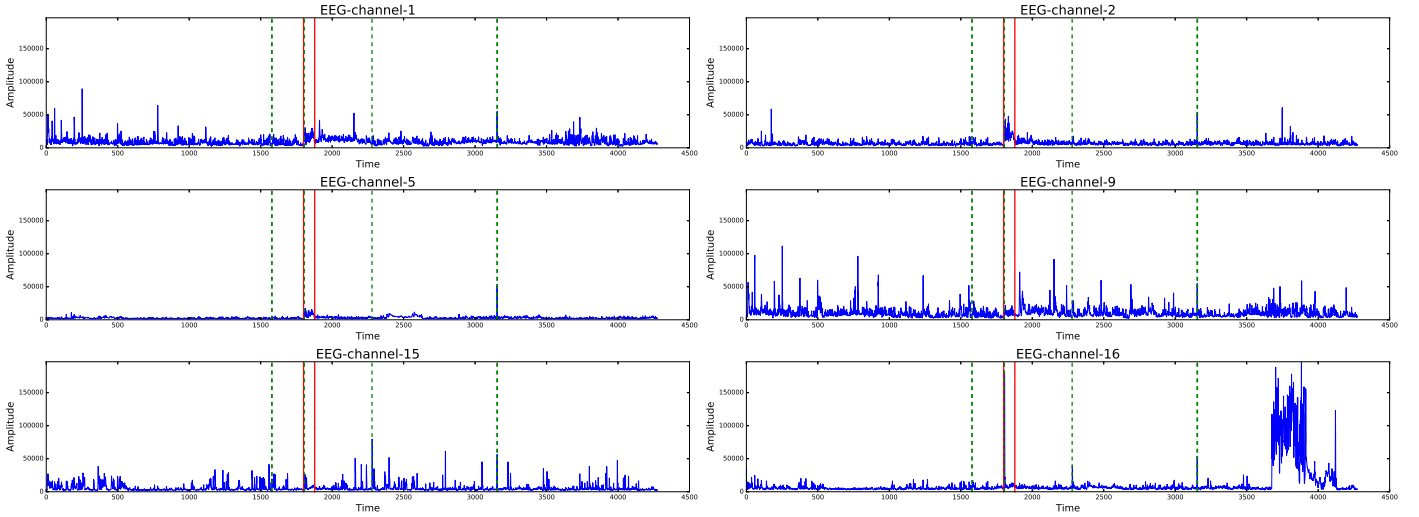
### V. DENEYLER VE DEĞERLENDİRME

Bayeşçi değişim noktası modelinin çıktısı, veri kümemizdeki her bir gözlem için değişim noktası olasılığının sonsal dağılımıdır. Bu olasılığın belirli bir eşik değeri aştığı durumlarda model bir *sinyal* üretmektedir. Biz bu çalışmada eşik değer olarak 0,99'u belirledik. Gerçekte var olan değişim noktalarının iskanmasının maliyetine bağlı olarak bu sayının ince ayarını yapmak mümkündür.

Problemdeki nihai amaç nöbetin gerçekleştiği zaman aralığını işaret etmektir. Bu nedenle, modelin ürettiği sinyallerin her biri yerine bu sinyallerin işaret ettiği bölütleri (*segment*) modelin çıktısı olarak kabul etmek yerinde olacaktır. Bunun için, birbirine  $T$  saniye uzaklıktaki sinyalleri aynı *komşuluk kümesine* dahil ettik ve modelin bulunduğu komşuluk kümelerini sonuç olarak ilan ettik. Nöbetlerin ortalama 76 saniye sürdüğünü dikkate alarak  $T$  süresini 10 saniye olarak belirledik.

Değişim noktası modelindeki  $\pi$ ,  $a$  ve  $b$  parametrelerini sırasıyla  $10^{-8}$ , 1 ve 2'ye sabitleyerek deneyleri gerçekleştirdik. Model, elimizdeki 48 veri setinin tamamında nöbetlerin gerçekleştiği aralıkları tespit etmeyi başardı. Bu veri kümelerinin üçünde toplam 99 komşuluk kümesi saptandı. Bu da, yaklaşık 2 dakikada bir uyarı yapıldığı anlamına geldiğinden bu örneklerde başarılı sonuç elde edildiğini söylemek güç. Geri kalan 45 veri setindeyse toplam 145 komşuluk kümesi bulundu.

Modelin örnek çıktılarından biri Şekil 2'de verilmiştir. Görüleceği üzere toplam 4 farklı komşuluk kümesi tespit edilirken bunların bir tanesi nörolog tarafından belirtilen aralığa denk gelmektedir. 2 ve 5 numaralı EEG kanallarından toplanan sinyallerde nöbetin gerçekleştiği zaman dilimi çıplak gözle ayırt edilebilirken diğer çizimler için aynısını söylemek mümkün değildir. Fark edileceği üzere, son komşuluk kümesinin gösterdiği saniyede tüm kanallarda bir sapma meydana gelmiştir. Bu, uğraştığımız problemin çetin yanlarını göstermek adına güzel bir örnektir. Son olarak, 16 numaralı EEG kanalından



Şekil 2: Modeli çalıştırdığımız örneklerden biri. Yer kısıtından ötürü ham EEG kayıtlarından türettiğimiz satırları düzgelenmiş pencereler arası fark matrisinin 6 satırını görselleştirdik. Yatay eksen zamanı, düşey eksen farkın büyüklüğünü temsil etmektedir. Kırmızı çizgiler nöbet başlangıç ve bitiş anlarını, kesikli yeşil çizgilerse modelin bulduğu komşulukları göstermektedir.

toplanan sinyalin son bölümlerinde büyük dalgalanmalar meydana gelmesine rağmen model çıktısı bu zaman dilimini işaret etmemektedir. Bunun sebebi, modelin çıktı üretirken bütün kanallardaki değişimleri dikkate almasıdır ve modelin gürbüz olduğunun göstergesidir.

## VI. VARGILAR VE İLERİ ÇALIŞMALAR

Biz bu çalışmada, epilepsi nöbetlerinin gerçekleştiği zaman dilimlerini çevrimdışı olarak saptayan bir Bayesçi değişim noktası modeli sunduk. Bu zaman dilimlerinin, dolayısıyla nöbet esnasında aktif olan bölgenin, tespiti epilepsi cerrahisinde hayati öneme sahiptir. Geliştirdiğimiz yöntemi, epilepsi hastalarından toplanan ve hastaların EEG ve EKG kayıtlarını içeren 48 farklı veri kümesine uyguladık. Bütün örneklerde nöbetin gerçekleştiği aralığın başarıyla tespit edildiğini gözlemledik.

Bayesçi değişim noktası modelimiz Poisson-Gamma gözlem modelini kullanmaktadır. Bununla beraber, Bölüm III'te anlatılan kısıtlara uyulduğu süreç başka gözlem modelleriyle deneyler yapılmak mümkündür. Değişim noktası modelinin parametreleri, beklenti enbüyüme (*Expectation-Maximization*) algoritması yardımıyla hastalara özel olarak öğrenilebilir.

Deneylerin sonuçlarından yaptığımız bir çıkarım, birden çok örnek kaydı olan hastalarda genelde birbirine yakın pencere genişliği ( $k$ ) değerlerinin iyi sonuç verdiğidir. İdeal değerleri hastalara özel çalışmalarla keşfetmek mümkündür. Benzer şekilde, kullandığımız öznitelik matrislerinden SD-PAFM-EEG en başarılı sonuçları üretmektedir. Diğer matrislerden SD-PAFM, SD-PAFM-EEG ile kıyaslanabilir başarımlarına sahipken SD-PAFM-EKG'nin yalnızca kimi hastalarda kabul edilebilir sonuçlar ürettiğini gözlemledik. Her hastaya en uygun olan veri matrislerinin keşfedilmesi de olası ileri çalışmalardan biridir.

## KAYNAKLAR

- [1] D. Barber and A. T. Cemgil, "Graphical models for time-series," *Signal Processing Magazine, IEEE*, vol. 27, no. 6, pp. 18–28, 2010.
- [2] Ç. Yıldız, Y. T. Ceritli, B. Kurt, B. Sankur, and A. T. Cemgil, "Bayesçi Çoklu değişim noktası modeliyle voip ağlarda saldırı tespiti," in *25. IEEE Sinyal İşleme ve İletişim Uygulamaları Kurultayı, SİU 2016*, 2016.
- [3] Y. Khan and J. Gotman, "Wavelet based automatic seizure detection in intracerebral electroencephalogram," *Clinical Neurophysiology*, vol. 114, no. 5, pp. 898–908, 2003.
- [4] H. Adeli, S. Ghosh-Dastidar, and N. Dadmehr, "A wavelet-chaos methodology for analysis of eegs and eeg subbands to detect seizure and epilepsy," *IEEE Transactions on Biomedical Engineering*, vol. 54, no. 2, pp. 205–211, 2007.
- [5] N. Radhakrishnan and B. Gangadhar, "Estimating regularity in epileptic seizure time-series data," *IEEE engineering in medicine and biology magazine*, vol. 17, no. 3, pp. 89–94, 1998.
- [6] L. Diambra, J. B. de Figueiredo, and C. P. Malta, "Epileptic activity recognition in eeg recording," *Physica A: Statistical Mechanics and its Applications*, vol. 273, no. 3, pp. 495–505, 1999.
- [7] V. Srinivasan, C. Eswaran, and N. Sriraam, "Approximate entropy-based epileptic eeg detection using artificial neural networks," *IEEE Transactions on information Technology in Biomedicine*, vol. 11, no. 3, pp. 288–295, 2007.
- [8] L. Guo, D. Rivero, and A. Pazos, "Epileptic seizure detection using multiwavelet transform based approximate entropy and artificial neural networks," *Journal of neuroscience methods*, vol. 193, no. 1, pp. 156–163, 2010.
- [9] E. Acar, C. Aykut-Bingöl, H. Bingöl, R. Bro, and B. Yener, "Multiway analysis of epilepsy tensors," *Bioinformatics*, vol. 23, no. 13, pp. i10–i18, 2007.
- [10] N. Dhulekar, B. Oztan, B. Yener, H. O. Bingöl, G. Irım, B. Aktekin, and C. Aykut-Bingöl, "Graph-theoretic analysis of epileptic seizures on scalp eeg recordings," in *Proceedings of the 5th ACM Conference on Bioinformatics, Computational Biology, and Health Informatics*. ACM, 2014, pp. 155–163.
- [11] T. N. Alotaiby, S. A. Alshebeili, T. Alshawi, I. Ahmad, and F. E. A. El-Samie, "Eeg seizure detection and prediction algorithms: a survey," *EURASIP Journal on Advances in Signal Processing*, vol. 2014, no. 1, p. 183, 2014.
- [12] P. Fearnhead, "Exact and efficient bayesian inference for multiple changepoint problems," *Statistics and computing*, vol. 16, no. 2, pp. 203–213, 2006.